

Explicação Simplificada - Parte 2: RAG, n8n e Integração Full-Stack

1. Objetivo: transformar um chatbot comum em um assistente capaz de ler documentos e responder perguntas usando esses documentos.
2. RAG: Recupera informações relevantes de documentos antes de enviar a pergunta para a IA.
3. Fases do RAG: Ingestão (ler, dividir, vetorizar e salvar documentos) e Recuperação (buscar informações relevantes quando o usuário pergunta).
4. Pipeline de ingestão: Parsing -> Chunking -> Embedding -> Persistência.
5. Embeddings: transformam textos em vetores numéricos que representam significados semelhantes.
6. RagService: orquestra os componentes, mas não executa diretamente buscas ou chamadas externas.
7. TOP_K define quantos fragmentos serão recuperados; MIN_SIMILARITY define o nível mínimo de relevância.
8. Frontend React deve mostrar respostas e também as fontes utilizadas.
9. n8n é um orquestrador externo para notificações e integrações.
10. Testes: validar API, RAG, frontend e n8n separadamente antes da integração completa.